INTELIGENCIA ARTIFICIAL I · RETO ACADÉMICO COLABORATIVO

IA en Juego

Glosario académico de inteligencia artificial

60 términos · 12 ejes temáticos + ampliación · fuentes rastreables (IEEE)

Asignatura	Inteligencia Artificial I
Integrantes	Ingrid Liseth Roa Manrique Jeimi Lorena Castro Cupa Juan Sebastian Gil
Fecha de elaboración	6 de noviembre de 2026
Producto complementario	Juego educativo y glosario web «ÉPOCA: entrena tu modelo»: https://letax67.github.io/epoca-ia/

Cómo consultar este glosario

Cada término tiene un identificador (G01–G60) y una ficha con seis campos: término en español e inglés, definición técnica con cita IEEE [n] y localizador, explicación propia, ejemplo de aplicación (marcado como *documentado*, *hipotético* o *calculado*), relaciones con otros términos del glosario y fuente rastreable. Algunas fichas incluyen una nota sobre divergencias entre fuentes o términos que se confunden con facilidad.

Este glosario también tiene una versión web con buscador, filtros por eje y el juego: https://letax67.github.io/epoca-ia/. Hay tres formas de buscar: el **índice por ejes** (página siguiente), el **índice alfabético** y los **enlaces internos**: en el PDF, los nombres de términos relacionados son vínculos que llevan a su ficha. Al final se encuentran la bibliografía IEEE, la matriz de trazabilidad de fuentes y la nota metodológica.

Ejemplo de lectura de una cita

«[3], entrada «overfitting»» significa: fuente número 3 de la bibliografía (Google for Developers, *Machine Learning Glossary*), buscando la entrada *overfitting*. «[9], cap. 6, sec. 6.5» significa: libro *Deep Learning*, capítulo 6, sección 6.5.

Tablas comparativas de apoyo

Concepto	Probabilidad	Odds	Log-odds
Fórmula	p	p / (1 − p)	ln(p / (1 − p))
Rango	0 a 1	0 a ∞	−∞ a +∞
p = 0,5	0,5	1 (1:1)	0
p = 0,8	0,8	4 (4:1)	≈ 1,39

Aspecto	KNN	K-means
Tipo de aprendizaje	Supervisado	No supervisado
Significado de K	Número de vecinos que votan	Número de grupos a formar
Necesita etiquetas	Sí	No
Comparte	Usa distancias (requiere escalar variables)	Usa distancias (requiere escalar variables)

Aspecto	Ajuste fino	RAG
¿Cambia los pesos del modelo?	Sí	No
¿Cómo agrega conocimiento?	Reentrenando con datos de la tarea	Recuperando documentos al responder
Información que cambia seguido	Requiere reentrenar	Basta con actualizar los documentos
Permite citar la fuente	Difícilmente	Sí, el documento recuperado

Índice por ejes

Eje 01 · Generalidades de ML

G01 Inteligencia artificial · Artificial intelligence (AI) 8
G02 Aprendizaje automático · Machine learning (ML) 8
G03 Conjunto de entrenamiento · Training set 9
G04 Inferencia · Inference 9

Eje 02 · Aprendizaje supervisado

G05 Etiqueta · Label 10
G06 Clasificación · Classification model 10
G07 Regresión · Regression model 10
G08 Conjuntos de validación y prueba · Validation set / Test set 11

Eje 03 · Aprendizaje no supervisado

G09 Agrupamiento · Clustering 12
G10 K-means · K-means 12
G11 DBSCAN · Density-Based Spatial Clustering of Applications with Noise 13
G12 Análisis de componentes principales · Principal Component Analysis (PCA) 13

Eje 04 · Aprendizaje profundo

G13 Aprendizaje profundo · Deep learning 14
G14 Aprendizaje de representaciones · Representation learning 14
G15 Convolución · Convolution 15
G16 Desvanecimiento del gradiente · Vanishing gradient problem 15

Eje 05 · Aprendizaje por refuerzo

G17 Agente · Agent (reinforcement learning) 16
G18 Recompensa · Reward 16
G19 Política · Policy 16
G20 Q-learning · Q-learning 17

Eje 06 · Algoritmos y aplicaciones

G21 Regresión logística · Logistic regression 18
G22 Árbol de decisión · Decision tree 18
G23 Bosque aleatorio · Random forest 18
G24 Sobreajuste · Overfitting 19

Eje 07 · Odds y probabilidades

G25 Odds · Odds 20
G26 Log-odds · Log-odds (logit) 20
G27 Probabilidad condicional · Conditional probability 20
G28 Teorema de Bayes · Bayes' theorem / Bayes' rule 21

Eje 08 · Texto computacional

G29 Procesamiento de lenguaje natural · Natural Language Processing (NLP / PLN) 22
G30 Tokenización · Tokenization 22
G31 TF-IDF · Term Frequency – Inverse Document Frequency 23

G32 Embedding · Embedding (vector de incrustación) 23

Eje 09 · Vecino más cercano

G33 K vecinos más cercanos · k-Nearest Neighbors (KNN) 24
G34 Hiperparámetro K · k / n_neighbors 24
G35 Distancia euclidiana · Euclidean distance 24
G36 Escalado de características · Feature scaling 25

Eje 10 · Principios de redes neuronales

G37 Neurona artificial · Artificial neuron (peso y sesgo) 26
G38 Función de activación · Activation function 26
G39 Descenso del gradiente · Gradient descent 27
G40 Retropropagación · Backpropagation 27

Eje 11 · Estructura de redes neuronales

G41 Red densa · Dense / fully connected network 28
G42 Red neuronal convolucional · Convolutional Neural Network (CNN) 28
G43 Red neuronal recurrente · Recurrent Neural Network (RNN) 28
G44 Transformer · Transformer 29

Eje 12 · Implicaciones sociales

G45 Sesgo algorítmico · Bias (in AI systems) 30
G46 Explicabilidad · Explainability 30
G47 Privacidad de datos · Privacy and data protection 31
G48 Supervisión humana · Human oversight 31

Ampliación · Ampliación: IA contemporánea

G49 IA generativa · Generative AI 32
G50 Modelo de lenguaje grande · Large Language Model (LLM) 32
G51 Modelo fundacional · Foundation model 33
G52 Prompt · Prompt 33
G53 Generación aumentada por recuperación · Retrieval-Augmented Generation (RAG) 33
G54 Agente de IA · AI agent 34
G55 IA multimodal · Multimodal model 34
G56 Ajuste fino · Fine-tuning 34
G57 Alucinación · Hallucination 35
G58 Base de datos vectorial · Vector database 35
G59 Modelo de difusión · Diffusion model 35
G60 Mantenimiento predictivo con IA · AI-based predictive maintenance 36

Índice alfabético

Incluye la denominación en inglés de cada término como entrada de búsqueda bilingüe.

Activation function → ver Función de activación G38 · p. 26
Agent → ver Agente G17 · p. 16
Agente G17 · p. 16
Agente de IA G54 · p. 34
Agrupamiento G09 · p. 12
AI agent → ver Agente de IA G54 · p. 34
AI-based predictive maintenance → ver Mantenimiento predictivo con IA G60 · p. 36
Ajuste fino G56 · p. 34
Alucinación G57 · p. 35
Análisis de componentes principales G12 · p. 13
Aprendizaje automático G02 · p. 8
Aprendizaje de representaciones G14 · p. 14
Aprendizaje profundo G13 · p. 14
Árbol de decisión G22 · p. 18
Artificial intelligence → ver Inteligencia artificial G01 · p. 8
Artificial neuron → ver Neurona artificial G37 · p. 26
Backpropagation → ver Retropropagación G40 · p. 27
Base de datos vectorial G58 · p. 35
Bayes' theorem / Bayes' rule → ver Teorema de Bayes G28 · p. 21
Bias → ver Sesgo algorítmico G45 · p. 30
Bosque aleatorio G23 · p. 18
Clasificación G06 · p. 10
Classification model → ver Clasificación G06 · p. 10
Clustering → ver Agrupamiento G09 · p. 12
Conditional probability → ver Probabilidad condicional G27 · p. 20
Conjunto de entrenamiento G03 · p. 9
Conjuntos de validación y prueba G08 · p. 11
Convolución G15 · p. 15
Convolution → ver Convolución G15 · p. 15
Convolutional Neural Network → ver Red neuronal convolucional G42 · p. 28
DBSCAN G11 · p. 13
Decision tree → ver Árbol de decisión G22 · p. 18
Inference → ver Inferencia G04 · p. 9
Inferencia G04 · p. 9
Inteligencia artificial G01 · p. 8
k / n_neighbors → ver Hiperparámetro K G34 · p. 24
K vecinos más cercanos G33 · p. 24
K-means G10 · p. 12
k-Nearest Neighbors → ver K vecinos más cercanos G33 · p. 24
Label → ver Etiqueta G05 · p. 10
Large Language Model → ver Modelo de lenguaje grande G50 · p. 32
Log-odds G26 · p. 20
Logistic regression → ver Regresión logística G21 · p. 18
Machine learning → ver Aprendizaje automático G02 · p. 8
Mantenimiento predictivo con IA G60 · p. 36
Modelo de difusión G59 · p. 35
Modelo de lenguaje grande G50 · p. 32
Modelo fundacional G51 · p. 33
Multimodal model → ver IA multimodal G55 · p. 34
Natural Language Processing → ver Procesamiento de lenguaje natural G29 · p. 22
Neurona artificial G37 · p. 26
Odds G25 · p. 20
Overfitting → ver Sobreajuste G24 · p. 19
Policy → ver Política G19 · p. 16
Política G19 · p. 16
Principal Component Analysis → ver Análisis de componentes principales G12 · p. 13
Privacidad de datos G47 · p. 31
Privacy and data protection → ver Privacidad de datos G47 · p. 31
Probabilidad condicional G27 · p. 20
Procesamiento de lenguaje natural G29 · p. 22
Prompt G52 · p. 33
Q-learning G20 · p. 17
Random forest → ver Bosque aleatorio G23 · p. 18
Recompensa G18 · p. 16

Deep learning → ver Aprendizaje profundo G13 · p. 14
Dense / fully connected network → ver Red densa G41 · p. 28
Density-Based Spatial Clustering of Applications with Noise → ver DBSCAN G11 · p. 13
Descenso del gradiente G39 · p. 27
Desvanecimiento del gradiente G16 · p. 15
Diffusion model → ver Modelo de difusión G59 · p. 35
Distancia euclidiana G35 · p. 24
Embedding G32 · p. 23
Escalado de características G36 · p. 25
Etiqueta G05 · p. 10
Euclidean distance → ver Distancia euclidiana G35 · p. 24
Explainability → ver Explicabilidad G46 · p. 30
Explicabilidad G46 · p. 30
Feature scaling → ver Escalado de características G36 · p. 25
Fine-tuning → ver Ajuste fino G56 · p. 34
Foundation model → ver Modelo fundacional G51 · p. 33
Función de activación G38 · p. 26
Generación aumentada por recuperación G53 · p. 33
Generative AI → ver IA generativa G49 · p. 32
Gradient descent → ver Descenso del gradiente G39 · p. 27
Hallucination → ver Alucinación G57 · p. 35
Hiperparámetro K G34 · p. 24
Human oversight → ver Supervisión humana G48 · p. 31
IA generativa G49 · p. 32
IA multimodal G55 · p. 34
Recurrent Neural Network → ver Red neuronal recurrente G43 · p. 28
Red densa G41 · p. 28
Red neuronal convolucional G42 · p. 28
Red neuronal recurrente G43 · p. 28
Regresión G07 · p. 10
Regresión logística G21 · p. 18
Regression model → ver Regresión G07 · p. 10
Representation learning → ver Aprendizaje de representaciones G14 · p. 14
Retrieval-Augmented Generation → ver Generación aumentada por recuperación G53 · p. 33
Retropropagación G40 · p. 27
Reward → ver Recompensa G18 · p. 16
Sesgo algorítmico G45 · p. 30
Sobreajuste G24 · p. 19
Supervisión humana G48 · p. 31
Teorema de Bayes G28 · p. 21
Term Frequency – Inverse Document Frequency → ver TF-IDF G31 · p. 23
TF-IDF G31 · p. 23
Tokenización G30 · p. 22
Tokenization → ver Tokenización G30 · p. 22
Training set → ver Conjunto de entrenamiento G03 · p. 9
Transformer G44 · p. 29
Validation set / Test set → ver Conjuntos de validación y prueba G08 · p. 11
Vanishing gradient problem → ver Desvanecimiento del gradiente G16 · p. 15
Vector database → ver Base de datos vectorial G58 · p. 35

Eje 01 · Generalidades de ML

G01 INTELIGENCIA ARTIFICIAL | Artificial intelligence (AI)

DEFINICIÓN TÉCNICA	Sistema basado en máquinas que, para objetivos explícitos o implícitos, infiere a partir de las entradas que recibe cómo generar salidas —predicciones, contenidos, recomendaciones o decisiones— que pueden influir en entornos físicos o virtuales. [7]
EXPLICACIÓN PROPIA	Es el campo amplio que busca que las máquinas realicen tareas asociadas a la inteligencia: reconocer, predecir, decidir o generar. No toda IA aprende de datos; también hay sistemas basados en reglas escritas por personas.
EJEMPLO	Documentado: las aplicaciones de navegación estiman tiempos de llegada y recomiendan rutas según el tráfico; generan predicciones y recomendaciones que influyen en decisiones reales.
RELACIONES	Aprendizaje automático (G02), IA generativa (G49), Agente de IA (G54)
FUENTE RASTREABLE	[7], definición actualizada de «AI system»; ver también [3], entrada «artificial intelligence»
NOTA	Divergencia: [3] la define de forma general como un programa o modelo no humano capaz de resolver tareas sofisticadas y señala que el ML es un subcampo de la IA; la OCDE [7] la define por el comportamiento del sistema (inferir salidas a partir de entradas). Se adopta la de la OCDE por ser más precisa y usada en política pública.

G02 APRENDIZAJE AUTOMÁTICO | Machine learning (ML)

DEFINICIÓN TÉCNICA	Programa o sistema que entrena un modelo a partir de datos de entrada, de modo que el modelo entrenado pueda hacer predicciones útiles sobre datos nuevos, nunca vistos. [3]
EXPLICACIÓN PROPIA	En lugar de programar cada regla a mano, se entregan ejemplos y el sistema descubre los patrones. Todo ML es IA, pero no toda IA es ML.
EJEMPLO	Documentado: los filtros de correo no deseado aprenden a reconocer spam a partir de mensajes marcados por los usuarios.
RELACIONES	Inteligencia artificial (G01), Conjunto de entrenamiento (G03), Etiqueta (G05), Aprendizaje profundo (G13)
FUENTE RASTREABLE	[3], entrada «machine learning»; ver también [2], cap. «What is Machine Learning?»

G03 CONJUNTO DE ENTRENAMIENTO | Training set

DEFINICIÓN TÉCNICA	Subconjunto del conjunto de datos que se utiliza para entrenar un modelo. [3]
EXPLICACIÓN PROPIA	Son los ejemplos con los que el modelo «estudia». Se separan de los datos de validación y prueba para comprobar después si aprendió de verdad o solo memorizó.
EJEMPLO	Hipotético: de 10 000 fotos de piezas, 7 000 se usan para entrenar un detector de defectos, 1 500 para validar y 1 500 para la prueba final.
RELACIONES	Conjuntos de validación y prueba (G08), Sobreajuste (G24), Etiqueta (G05)
FUENTE RASTREABLE	[3], entrada «training set»

G04 INFERENCIA | Inference

DEFINICIÓN TÉCNICA	En aprendizaje automático, proceso de generar predicciones aplicando un modelo ya entrenado a ejemplos sin etiquetar. [3]
EXPLICACIÓN PROPIA	Si entrenar es «estudiar», inferir es «presentar el examen»: el modelo ya no aprende, solo usa lo aprendido para responder ante datos nuevos.
EJEMPLO	Hipotético: el detector de defectos entrenado recibe la foto de una pieza recién fabricada y responde «defectuosa, 92 %» en milisegundos.
RELACIONES	Aprendizaje automático (G02), Clasificación (G06), Modelo de lenguaje grande (G50)
FUENTE RASTREABLE	[3], entrada «inference»
NOTA	Divergencia: en estadística, «inferencia» significa sacar conclusiones sobre una población a partir de una muestra. Aquí se usa el sentido de ML.

Eje 02 · Aprendizaje supervisado

G05 ETIQUETA | Label

DEFINICIÓN TÉCNICA	En aprendizaje supervisado, la parte «respuesta» o «resultado» de un ejemplo; cada ejemplo etiquetado consta de una o más características y una etiqueta. [3]
EXPLICACIÓN PROPIA	Es la respuesta correcta que ya conocemos antes de entrenar. Por eso el aprendizaje se llama supervisado: alguien aportó las respuestas.
EJEMPLO	Hipotético: en un historial de máquinas, la columna «falló en los próximos 30 días: sí/no» es la etiqueta; temperatura y vibración son características.
RELACIONES	Clasificación (G06), Regresión (G07), Conjunto de entrenamiento (G03)
FUENTE RASTREABLE	[3], entrada «label»

G06 CLASIFICACIÓN | Classification model

DEFINICIÓN TÉCNICA	Modelo cuya predicción es una clase, es decir, una categoría de un conjunto finito de valores posibles. [3]
EXPLICACIÓN PROPIA	Responde preguntas de tipo «¿cuál de estas categorías?». Si solo hay dos opciones es clasificación binaria; si hay más, multiclase.
EJEMPLO	Hipotético: clasificar cada pieza de una línea de producción como «aceptada» o «rechazada».
RELACIONES	Regresión (G07), Regresión logística (G21), K vecinos más cercanos (G33), Árbol de decisión (G22)
FUENTE RASTREABLE	[3], entrada «classification model»

G07 REGRESIÓN | Regression model

DEFINICIÓN TÉCNICA	Modelo que genera una predicción numérica (un valor continuo). [3]
EXPLICACIÓN PROPIA	Responde «¿cuánto?» en lugar de «¿cuál?». Ojo: la regresión logística, pese a su nombre, se usa para clasificar.
EJEMPLO	Hipotético: predecir cuántas horas de vida útil le quedan a un rodamiento a partir de su vibración.
RELACIONES	Clasificación (G06), Regresión logística (G21), Mantenimiento predictivo con IA (G60)
FUENTE RASTREABLE	[3], entrada «regression model»; ver [1], sec. 2.7 «Classification vs. Regression» y sec. 3.1

G08 CONJUNTOS DE VALIDACIÓN Y PRUEBA | Validation set / Test set

DEFINICIÓN TÉCNICA	El conjunto de validación es el subconjunto usado para evaluar un modelo durante el desarrollo y ajustar hiperparámetros; el conjunto de prueba es un subconjunto reservado para la evaluación final del modelo. [3]
EXPLICACIÓN PROPIA	Validación = ensayos durante el desarrollo; prueba = examen final que se usa una sola vez. Si se usa la prueba para tomar decisiones, deja de medir la generalización real.
EJEMPLO	Hipotético: con el conjunto de validación se elige K = 5 en un KNN; al final se reporta el acierto sobre el conjunto de prueba, nunca usado antes.
RELACIONES	Conjunto de entrenamiento (G03), Sobreajuste (G24), Hiperparámetro K (G34)
FUENTE RASTREABLE	[3], entradas «validation set» y «test set»

Eje 03 · Aprendizaje no supervisado

G09 AGRUPAMIENTO | Clustering

DEFINICIÓN TÉCNICA	Agrupar ejemplos relacionados, especialmente durante el aprendizaje no supervisado; luego, una persona puede interpretar el significado de cada grupo. [3]
EXPLICACIÓN PROPIA	No hay etiquetas: el algoritmo agrupa por parecido y una persona interpreta después qué representa cada grupo.
EJEMPLO	Hipotético: agrupar clientes por hábitos de compra para descubrir segmentos que no se conocían.
RELACIONES	K-means (G10), DBSCAN (G11), Clasificación (G06)
FUENTE RASTREABLE	[3], entrada «clustering»; ver [2], capítulo «Clustering»
NOTA	Distinción clave: clasificar asigna categorías conocidas (supervisado); agrupar descubre grupos (no supervisado).

G10 K-MEANS | K-means

DEFINICIÓN TÉCNICA	Algoritmo que agrupa los datos tratando de separarlos en K grupos de igual varianza, minimizando la inercia (suma de distancias cuadradas de cada punto al centroide de su grupo). [4]
EXPLICACIÓN PROPIA	Se eligen K centros, cada punto se asigna al más cercano, los centros se recalculan y se repite hasta estabilizarse. Hay que decidir K de antemano.
EJEMPLO	Hipotético: agrupar sensores de una planta en 3 grupos según su patrón de temperatura y vibración.
RELACIONES	Agrupamiento (G09), DBSCAN (G11), Distancia euclidiana (G35), K vecinos más cercanos (G33)
FUENTE RASTREABLE	[4], sección «Clustering», apartado «K-means»
NOTA	No confundir con KNN: K-means es no supervisado (K = número de grupos); KNN es supervisado (K = número de vecinos).

G11 DBSCAN | Density-Based Spatial Clustering of Applications with Noise

DEFINICIÓN TÉCNICA	Algoritmo de agrupamiento basado en densidad: forma grupos con regiones de alta densidad de puntos y marca como ruido los puntos situados en regiones de baja densidad. [16]
EXPLICACIÓN PROPIA	No necesita saber cuántos grupos hay, encuentra grupos de forma irregular y separa los puntos «raros» como ruido.
EJEMPLO	Hipotético: en lecturas de vibración con mediciones atípicas, DBSCAN separa los regímenes normales de operación y deja aparte las lecturas anómalas.
RELACIONES	Agrupamiento (G09), K-means (G10), Mantenimiento predictivo con IA (G60)
FUENTE RASTREABLE	[16]; ver [4], sección «Clustering», apartado «DBSCAN»

G12 ANÁLISIS DE COMPONENTES PRINCIPALES | Principal Component Analysis (PCA)

DEFINICIÓN TÉCNICA	Técnica de reducción dimensional que descompone un conjunto de datos multivariado en componentes ortogonales sucesivos que explican la máxima cantidad de varianza. [4]
EXPLICACIÓN PROPIA	Resume muchas variables en pocas «direcciones» que conservan la mayor parte de la información. Sirve para visualizar y para acelerar otros algoritmos.
EJEMPLO	Hipotético: 50 mediciones por pieza se reducen a 2 componentes para graficar y ver si las piezas defectuosas se separan de las buenas.
RELACIONES	Agrupamiento (G09), Escalado de características (G36), Embedding (G32)
FUENTE RASTREABLE	[4], sección «Decomposing signals in components», apartado «PCA»

Eje 04 · Aprendizaje profundo

G13 APRENDIZAJE PROFUNDO | Deep learning

DEFINICIÓN TÉCNICA	Enfoque de aprendizaje automático que permite a las computadoras aprender de la experiencia y entender el mundo como una jerarquía de conceptos, cada uno definido a partir de otros más simples, mediante modelos de muchas capas. [9]
EXPLICACIÓN PROPIA	Usa redes neuronales con muchas capas. Cada capa aprende algo más abstracto que la anterior: bordes, luego formas, luego objetos.
EJEMPLO	Documentado: el reconocimiento de imágenes y de voz de los teléfonos actuales se basa en redes profundas.
RELACIONES	Aprendizaje de representaciones (G14), Red neuronal convolucional (G42), Neurona artificial (G37), Aprendizaje automático (G02)
FUENTE RASTREABLE	[9], cap. 1 «Introduction», p. 1; ver [3], entrada «deep model»

G14 APRENDIZAJE DE REPRESENTACIONES | Representation learning

DEFINICIÓN TÉCNICA	Uso del aprendizaje automático para descubrir no solo la correspondencia entre la representación de los datos y la salida, sino también la propia representación. [9]
EXPLICACIÓN PROPIA	En vez de que una persona diseñe a mano las características, el modelo aprende qué rasgos de los datos son útiles. Responde a «¿qué aportan varias capas?».
EJEMPLO	Hipotético: una red entrenada con fotos de soldaduras aprende sola a detectar porosidades, sin que nadie le diga que mire «poros».
RELACIONES	Aprendizaje profundo (G13), Embedding (G32), Red neuronal convolucional (G42)
FUENTE RASTREABLE	[9], cap. 1 y cap. 15 «Representation Learning»

G15 CONVOLUCIÓN | Convolution

DEFINICIÓN TÉCNICA	Operación que combina una entrada con un núcleo (kernel o filtro) deslizándolo sobre ella; en redes neuronales permite detectar patrones locales con parámetros compartidos. [9]
EXPLICACIÓN PROPIA	Un filtro pequeño recorre la imagen y «se enciende» donde encuentra el patrón que busca (por ejemplo, un borde). El mismo filtro sirve en toda la imagen.
EJEMPLO	Hipotético: un filtro que detecta líneas finas ayuda a encontrar grietas en fotos de piezas impresas en 3D.
RELACIONES	Red neuronal convolucional (G42), Aprendizaje profundo (G13), Neurona artificial (G37)
FUENTE RASTREABLE	[9], cap. 9, sec. 9.1 «The Convolution Operation», p. 322; ver [3], entrada «convolution»

G16 DESVANECIMIENTO DEL GRADIENTE | Vanishing gradient problem

DEFINICIÓN TÉCNICA	Tendencia de los gradientes de las primeras capas ocultas de algunas redes profundas a volverse sorprendentemente pequeños, de modo que esas capas se entrenan muy lentamente o casi nada. [3]
EXPLICACIÓN PROPIA	Al propagar el error hacia atrás por muchas capas, la señal se multiplica por números pequeños y se apaga: las primeras capas casi no aprenden.
EJEMPLO	Documentado: es una de las razones por las que las RNN clásicas olvidaban dependencias lejanas y surgieron LSTM y luego los Transformers.
RELACIONES	Retropropagación (G40), Función de activación (G38), Red neuronal recurrente (G43), Descenso del gradiente (G39)
FUENTE RASTREABLE	[3], entrada «vanishing gradient problem»; ver [9], cap. 10, sec. 10.7, p. 390

Eje 05 · Aprendizaje por refuerzo

G17 AGENTE | Agent (reinforcement learning)

DEFINICIÓN TÉCNICA	En aprendizaje por refuerzo, la entidad que aprende y toma decisiones; interactúa con un entorno observando su estado, eligiendo acciones y recibiendo recompensas. [10]
EXPLICACIÓN PROPIA	Es quien «juega»: observa la situación (estado), hace algo (acción) y recibe un puntaje (recompensa). Aprende de la experiencia, no de respuestas correctas dadas.
EJEMPLO	Hipotético: un brazo robótico que aprende a apilar cajas probando movimientos y recibiendo puntos cuando la pila queda estable.
RELACIONES	Recompensa (G18), Política (G19), Q-learning (G20), Agente de IA (G54)
FUENTE RASTREABLE	[10], cap. 1, sec. 1.3 y cap. 3; ver [3], entrada «agent»
NOTA	Divergencia: «agente» tiene otro sentido en IA generativa (ver «Agente de IA»).

G18 RECOMPENSA | Reward

DEFINICIÓN TÉCNICA	Señal numérica que el entorno envía al agente en cada paso y que define el objetivo del problema; el agente busca maximizar la recompensa total a largo plazo. [10]
EXPLICACIÓN PROPIA	Es el «marcador» que le dice al agente qué tan bien lo hizo. Mal diseñada, el agente puede encontrar trucos que suben el puntaje sin resolver la tarea.
EJEMPLO	Hipotético: en un sistema de climatización, +1 por mantener la temperatura objetivo y −1 por cada kWh extra consumido.
RELACIONES	Agente (G17), Política (G19), Q-learning (G20)
FUENTE RASTREABLE	[10], cap. 1, sec. 1.3 y cap. 3

G19 POLÍTICA | Policy

DEFINICIÓN TÉCNICA	Regla de decisión del agente: correspondencia entre los estados percibidos del entorno y las acciones que se toman en esos estados. [10]
EXPLICACIÓN PROPIA	Es la «estrategia» del agente: dada una situación, qué hacer. Aprender en RL es mejorar la política.
EJEMPLO	Hipotético: «si la batería del robot está por debajo del 20 %, ir a la estación de carga».
RELACIONES	Agente (G17), Recompensa (G18), Q-learning (G20)
FUENTE RASTREABLE	[10], cap. 1, sec. 1.3

G20 Q-LEARNING | Q-learning

DEFINICIÓN TÉCNICA	Algoritmo de aprendizaje por refuerzo de diferencia temporal, fuera de política, que aprende una función de valor acción-estado Q que aproxima la óptima, independientemente de la política que se siga. [10]
EXPLICACIÓN PROPIA	El agente llena una tabla: «¿qué tan bueno es hacer la acción A en el estado S?». Con cada experiencia corrige el valor usando la recompensa recibida y lo mejor que espera después.
EJEMPLO	Hipotético: un robot de bodega aprende la ruta más corta en una cuadrícula actualizando su tabla Q tras cada movimiento.
RELACIONES	Agente (G17), Política (G19), Recompensa (G18)
FUENTE RASTREABLE	[10], cap. 6, sec. 6.5 «Q-learning: Off-policy TD Control», p. 131

Eje 06 · Algoritmos y aplicaciones

G21 REGRESIÓN LOGÍSTICA | Logistic regression

DEFINICIÓN TÉCNICA	Modelo que predice una probabilidad aplicando la función sigmoide a una combinación lineal de las características; se usa sobre todo en clasificación binaria. [3]
EXPLICACIÓN PROPIA	Calcula un puntaje (que en realidad son log-odds) y lo convierte en probabilidad entre 0 y 1. Si supera un umbral, se asigna la clase positiva.
EJEMPLO	Hipotético: estimar la probabilidad de que un cliente abandone un servicio a partir de su uso mensual.
RELACIONES	Log-odds (G26), Odds (G25), Clasificación (G06), Función de activación (G38)
FUENTE RASTREABLE	[3], entrada «logistic regression»; ver [1], cap. 3, sec. 3.2 «Logistic Regression»

G22 ÁRBOL DE DECISIÓN | Decision tree

DEFINICIÓN TÉCNICA	Modelo de aprendizaje supervisado compuesto por condiciones y hojas organizadas jerárquicamente; cada condición divide los datos hasta llegar a una predicción. [3]
EXPLICACIÓN PROPIA	Es como un juego de «20 preguntas»: «¿temperatura > 80 °C? → sí → ¿vibración alta? → sí → fallo probable». Es fácil de explicar.
EJEMPLO	Hipotético: decidir si aprobar un lote según humedad, temperatura de impresión y espesor de capa.
RELACIONES	Bosque aleatorio (G23), Sobreajuste (G24), Explicabilidad (G46)
FUENTE RASTREABLE	[3], entrada «decision tree»; ver [1], cap. 3, sec. 3.3 «Decision Tree Learning», p. 27

G23 BOSQUE ALEATORIO | Random forest

DEFINICIÓN TÉCNICA	Combinación de árboles de decisión, cada uno construido con una muestra aleatoria de los datos y de las variables, cuyas predicciones se agregan por voto o promedio. [17]
EXPLICACIÓN PROPIA	Muchos árboles un poco distintos votan juntos. Los errores individuales se compensan; por eso se sobreajusta menos que un solo árbol.
EJEMPLO	Hipotético: predecir si una máquina CNC fallará esta semana combinando 300 árboles entrenados con datos de sensores.
RELACIONES	Árbol de decisión (G22), Sobreajuste (G24), Mantenimiento predictivo con IA (G60)
FUENTE RASTREABLE	[17]; ver [3], entrada «random forest»

G24 SOBREAJUSTE | Overfitting

DEFINICIÓN TÉCNICA	Crear un modelo que se ajusta tan estrechamente a los datos de entrenamiento que no logra hacer predicciones correctas sobre datos nuevos. [3]
EXPLICACIÓN PROPIA	El modelo «memoriza» en vez de aprender el patrón. Se detecta cuando va muy bien en entrenamiento y mal en validación o prueba.
EJEMPLO	Hipotético: un detector de defectos acierta el 99 % en las fotos de entrenamiento, pero solo el 70 % en un lote nuevo con otra iluminación.
RELACIONES	Conjuntos de validación y prueba (G08), Bosque aleatorio (G23), Árbol de decisión (G22)
FUENTE RASTREABLE	[3], entrada «overfitting»; ver [2], capítulo «Bias & Variance»

Eje 07 · Odds y probabilidades

G25 ODDS | Odds

DEFINICIÓN TÉCNICA	Cociente entre la probabilidad de que ocurra un evento y la probabilidad de que no ocurra: odds = p / (1 − p). [3]
EXPLICACIÓN PROPIA	La probabilidad va de 0 a 1; las odds comparan ocurrir frente a no ocurrir y van de 0 a infinito.
EJEMPLO	Calculado: si p = 0,75, odds = 0,75 / 0,25 = 3, es decir, 3:1 a favor. Probabilidad del 75 % y odds de 3:1 describen la misma situación con medidas distintas.
RELACIONES	Log-odds (G26), Regresión logística (G21), Probabilidad condicional (G27)
FUENTE RASTREABLE	[3], entrada «log-odds»

G26 LOG-ODDS | Log-odds (logit)

DEFINICIÓN TÉCNICA	Logaritmo de las odds de un evento: log(p / (1 − p)); es la escala en la que trabaja internamente la regresión logística. [3]
EXPLICACIÓN PROPIA	Lleva las odds a una escala de −∞ a +∞, simétrica alrededor de 0 (p = 0,5). La función sigmoide hace el camino inverso.
EJEMPLO	Calculado: p = 0,8 → odds = 4 → log-odds = ln 4 ≈ 1,39. Con p = 0,2 → odds = 0,25 → log-odds ≈ −1,39.
RELACIONES	Odds (G25), Regresión logística (G21), Función de activación (G38)
FUENTE RASTREABLE	[3], entrada «log-odds»

G27 PROBABILIDAD CONDICIONAL | Conditional probability

DEFINICIÓN TÉCNICA	Probabilidad de un evento A sabiendo que ocurrió otro evento B: P(A | B) = P(A y B) / P(B), con P(B) > 0. [1]
EXPLICACIÓN PROPIA	Es la probabilidad «actualizada» con información nueva: no es lo mismo la probabilidad de lluvia que la probabilidad de lluvia sabiendo que el cielo está nublado.
EJEMPLO	Calculado (hipotético): de 1 000 piezas, 50 son defectuosas y 40 de ellas tienen rayas; P(raya | defectuosa) = 40/50 = 0,8.
RELACIONES	Teorema de Bayes (G28), Odds (G25)
FUENTE RASTREABLE	[1], cap. 2 «Notation and Definitions»

G28 TEOREMA DE BAYES | Bayes' theorem / Bayes' rule

DEFINICIÓN TÉCNICA	Regla que relaciona probabilidades condicionales inversas: P(A | B) = P(B | A) · P(A) / P(B). [1]
EXPLICACIÓN PROPIA	Permite «darle la vuelta» a una probabilidad: de «qué tan probable es la señal si hay defecto» a «qué tan probable es el defecto si veo la señal».
EJEMPLO	Calculado: 2 % de piezas defectuosas; el sensor detecta el 90 % de los defectos y da 5 % de falsas alarmas. P(defecto | alarma) = 0,018 / (0,018 + 0,049) ≈ 27 %, no 90 %.
RELACIONES	Probabilidad condicional (G27), Odds (G25)
FUENTE RASTREABLE	[1], cap. 2, sec. 2.4 «Bayes' Rule», p. 17

Eje 08 · Texto computacional

G29 PROCESAMIENTO DE LENGUAJE NATURAL | Natural Language Processing (NLP / PLN)

DEFINICIÓN TÉCNICA	Campo de la computación y la IA que desarrolla métodos para que las computadoras procesen, analicen y generen lenguaje humano, hablado o escrito. [11]
EXPLICACIÓN PROPIA	Es lo que permite a una máquina «trabajar con palabras»: traducir, resumir, clasificar opiniones o conversar.
EJEMPLO	Documentado: traductores automáticos, correctores ortográficos y asistentes de voz.
RELACIONES	Tokenización (G30), TF-IDF (G31), Embedding (G32), Modelo de lenguaje grande (G50)
FUENTE RASTREABLE	[11], cap. 1 «Introduction»

G30 TOKENIZACIÓN | Tokenization

DEFINICIÓN TÉCNICA	Tarea de segmentar un texto en unidades llamadas tokens (palabras, subpalabras, caracteres o signos) que el sistema procesará. [11]
EXPLICACIÓN PROPIA	Es el primer paso para volver numérico un texto: partirlo en piezas. Los LLM suelen usar subpalabras, por eso una palabra larga puede ocupar varios tokens.
EJEMPLO	Hipotético: «La pieza falló» → [«La», «pieza», «falló»] o, con subpalabras, [«La», «pie», «za», «fall», «ó»].
RELACIONES	Procesamiento de lenguaje natural (G29), TF-IDF (G31), Modelo de lenguaje grande (G50), Prompt (G52)
FUENTE RASTREABLE	[11], cap. 2 «Words and Tokens»; ver [3], entrada «token»

G31 TF-IDF | Term Frequency – Inverse Document Frequency

DEFINICIÓN TÉCNICA	Ponderación que multiplica la frecuencia de un término en un documento (tf) por el logaritmo inverso de la proporción de documentos que lo contienen (idf), dando más peso a palabras frecuentes en un documento pero raras en la colección. [11]
EXPLICACIÓN PROPIA	Las palabras que aparecen en todos lados («el», «de») valen poco; las que caracterizan a un documento valen mucho. Mejora la «bolsa de palabras» simple.
EJEMPLO	Hipotético: en reportes de mantenimiento, «rodamiento» obtiene alto TF-IDF en los reportes de fallas mecánicas y bajo en los eléctricos.
RELACIONES	Tokenización (G30), Embedding (G32), Procesamiento de lenguaje natural (G29)
FUENTE RASTREABLE	[11], cap. 11 «Information Retrieval and Retrieval-Augmented Generation», apartado tf-idf
NOTA	Nota de fuente: en ediciones anteriores del libro de Jurafsky y Martin, tf-idf estaba en el capítulo «Vector Semantics and Embeddings»; en la versión en línea de 2026 se trasladó al capítulo 11.

G32 EMBEDDING | Embedding (vector de incrustación)

DEFINICIÓN TÉCNICA	Representación de un elemento (palabra, frase, imagen) como un vector de números reales en un espacio de menor dimensión, de forma que los elementos similares quedan cerca. [3]
EXPLICACIÓN PROPIA	Convierte significado en coordenadas: «tornillo» y «perno» quedan cerca; «tornillo» y «poema», lejos. La similitud semántica se mide con la distancia o el coseno.
EJEMPLO	Hipotético: un buscador de manuales encuentra «el motor se calienta» aunque el documento diga «sobretemperatura del motor».
RELACIONES	TF-IDF (G31), Base de datos vectorial (G58), Generación aumentada por recuperación (G53), Aprendizaje de representaciones (G14)
FUENTE RASTREABLE	[3], entrada «embedding vector»; ver [11], cap. 5 «Embeddings»

Eje 09 · Vecino más cercano

G33 K VECINOS MÁS CERCANOS | k-Nearest Neighbors (KNN)

DEFINICIÓN TÉCNICA	Algoritmo no paramétrico basado en instancias: guarda los ejemplos de entrenamiento y, para un ejemplo nuevo, busca los k más cercanos y predice la etiqueta mayoritaria (clasificación) o el promedio (regresión). [1]
EXPLICACIÓN PROPIA	«Dime con quién andas y te diré quién eres»: no construye un modelo explícito, compara con los ejemplos guardados y los vecinos votan.
EJEMPLO	Hipotético: clasificar una pieza nueva como buena o defectuosa según sus 5 piezas más parecidas en peso y dimensiones.
RELACIONES	Hiperparámetro K (G34), Distancia euclidiana (G35), Escalado de características (G36), K-means (G10)
FUENTE RASTREABLE	[1], cap. 3, sec. 3.5 «k-Nearest Neighbors», p. 34; ver [4], sección «Nearest Neighbors»

G34 HIPERPARÁMETRO K | k / n_neighbors

DEFINICIÓN TÉCNICA	Número de vecinos considerados en la predicción de KNN; es un hiperparámetro, es decir, un valor que se fija antes de entrenar y que el algoritmo no aprende. [4]
EXPLICACIÓN PROPIA	K pequeño: sensible al ruido (riesgo de sobreajuste). K grande: suaviza demasiado y puede ignorar grupos pequeños. Con dos clases se prefiere K impar para evitar empates.
EJEMPLO	Hipotético: con K = 1 una pieza mal etiquetada contamina la predicción; con K = 7 su efecto se diluye.
RELACIONES	K vecinos más cercanos (G33), Sobreajuste (G24), Conjuntos de validación y prueba (G08)
FUENTE RASTREABLE	[4], sección «Nearest Neighbors» (parámetro n_neighbors); ver [3], entrada «hyperparameter»

G35 DISTANCIA EUCLIDIANA | Euclidean distance

DEFINICIÓN TÉCNICA	Distancia en línea recta entre dos puntos: la raíz cuadrada de la suma de las diferencias al cuadrado de sus coordenadas. [3]
EXPLICACIÓN PROPIA	Es la distancia «con regla». KNN y K-means la usan para decidir qué tan parecidos son dos ejemplos.
EJEMPLO	Calculado: entre (1, 2) y (4, 6): $\sqrt{((4-1)^2 + (6-2)^2)} = \sqrt{(9 + 16)} = 5$.
RELACIONES	K vecinos más cercanos (G33), K-means (G10), Escalado de características (G36)
FUENTE RASTREABLE	[3], entrada «k-median» (glosario de agrupamiento), donde se define la distancia euclidiana que usa k-means

G36 ESCALADO DE CARACTERÍSTICAS | Feature scaling

DEFINICIÓN TÉCNICA	Transformación de las variables para llevarlas a rangos comparables, por ejemplo estandarizar a media 0 y desviación estándar 1, o normalizar al rango [0, 1]. [3]
EXPLICACIÓN PROPIA	Si una variable está en gramos (miles) y otra en milímetros (decenas), la primera domina la distancia. Escalar pone a todas en igualdad de condiciones.
EJEMPLO	Hipotético: en KNN con peso (0–5 000 g) y espesor (0–10 mm), sin escalar el espesor casi no influye en la decisión.
RELACIONES	Distancia euclidiana (G35), K vecinos más cercanos (G33), Análisis de componentes principales (G12)
FUENTE RASTREABLE	[3], entrada «normalization»; ver [4], sección «Preprocessing data», apartado «Standardization», y [1], cap. 5 «Basic Practice»

Eje 10 · Principios de redes neuronales

G37 NEURONA ARTIFICIAL | Artificial neuron (peso y sesgo)

DEFINICIÓN TÉCNICA	Unidad de una capa oculta de una red neuronal que calcula la suma ponderada de sus entradas multiplicadas por sus pesos y pasa ese resultado a una función de activación; los modelos añaden además un término de sesgo (bias), que es un parámetro aprendido. [3]
EXPLICACIÓN PROPIA	Es una pequeña calculadora: multiplica cada entrada por su importancia (peso), suma, agrega un ajuste (sesgo) y decide cuánto «activarse». Pesos y sesgos son lo que se ajusta al aprender.
EJEMPLO	Calculado: entradas (2, 3), pesos (0,5; −1), sesgo 1 → 2·0,5 + 3·(−1) + 1 = −1; con ReLU la salida es 0.
RELACIONES	Función de activación (G38), Retropropagación (G40), Red densa (G41), Sesgo algorítmico (G45)
FUENTE RASTREABLE	[3], entradas «neuron» y «bias (math) or bias term»; ver [2], cap. «Artificial Neural Networks»
NOTA	Atención: el «sesgo» (bias) de una neurona es un parámetro numérico; no tiene relación con el «sesgo algorítmico» del eje 12.

G38 FUNCIÓN DE ACTIVACIÓN | Activation function

DEFINICIÓN TÉCNICA	Función que permite a las redes neuronales aprender relaciones no lineales (complejas) entre las características y la etiqueta; ejemplos: ReLU, sigmoide, tanh. [3]
EXPLICACIÓN PROPIA	Sin ella, apilar capas equivaldría a una sola operación lineal. La activación da a la red la capacidad de representar curvas y patrones complejos.
EJEMPLO	Calculado: ReLU(x) = máx(0, x): ReLU(−3) = 0; ReLU(2) = 2. Sigmoide(0) = 0,5.
RELACIONES	Neurona artificial (G37), Log-odds (G26), Desvanecimiento del gradiente (G16)
FUENTE RASTREABLE	[3], entrada «activation function»

G39 DESCENSO DEL GRADIENTE | Gradient descent

DEFINICIÓN TÉCNICA	Método de optimización que minimiza una función moviéndose iterativamente en la dirección opuesta al gradiente, es decir, la dirección de mayor descenso. [9]
EXPLICACIÓN PROPIA	Como bajar una montaña con niebla: en cada paso se mira hacia dónde baja más el terreno y se avanza. El tamaño del paso es la tasa de aprendizaje.
EJEMPLO	Hipotético: si la tasa de aprendizaje es muy grande, el entrenamiento «salta» y no converge; si es muy pequeña, tarda demasiado.
RELACIONES	Retropropagación (G40), Neurona artificial (G37), Desvanecimiento del gradiente (G16)
FUENTE RASTREABLE	[9], cap. 4, sec. 4.3 «Gradient-Based Optimization», p. 79; ver [3], entrada «gradient descent»

G40 RETROPROPAGACIÓN | Backpropagation

DEFINICIÓN TÉCNICA	Algoritmo que calcula eficientemente el gradiente de la función de pérdida respecto a cada peso de la red, propagando la información del error desde la salida hacia las capas anteriores mediante la regla de la cadena. [9]
EXPLICACIÓN PROPIA	Calcula «cuánta culpa» tiene cada peso del error final. Luego el descenso del gradiente usa esa información para corregir los pesos.
EJEMPLO	Hipotético: la red predice 0,9 y la respuesta era 0; la retropropagación reparte ese error capa por capa hasta los primeros pesos.
RELACIONES	Descenso del gradiente (G39), Desvanecimiento del gradiente (G16), Neurona artificial (G37)
FUENTE RASTREABLE	[9], cap. 6, sec. 6.5 «Back-Propagation and Other Differentiation Algorithms», p. 197; ver [3], entrada «backpropagation»

Eje 11 · Estructura de redes neuronales

G41 RED DENSA | Dense / fully connected network

DEFINICIÓN TÉCNICA	Red formada por capas densas, en las que cada nodo está conectado con todos los nodos de la capa siguiente; se organiza en capa de entrada, capas ocultas y capa de salida. [3]
EXPLICACIÓN PROPIA	Es la arquitectura básica: la capa de entrada recibe los datos, las ocultas transforman y la de salida entrega la predicción. Funciona bien con datos tabulares.
EJEMPLO	Hipotético: 10 lecturas de sensores → 2 capas ocultas de 32 neuronas → 1 salida con la probabilidad de falla.
RELACIONES	Neurona artificial (G37), Red neuronal convolucional (G42), Red neuronal recurrente (G43)
FUENTE RASTREABLE	[3], entradas «dense layer» y «hidden layer»

G42 RED NEURONAL CONVOLUCIONAL | Convolutional Neural Network (CNN)

DEFINICIÓN TÉCNICA	Red neuronal que usa la convolución en lugar de la multiplicación matricial general en al menos una de sus capas; especializada en datos con estructura de cuadrícula, como imágenes. [9]
EXPLICACIÓN PROPIA	Ideal para imágenes: sus filtros detectan patrones locales sin importar dónde aparezcan y necesita muchos menos parámetros que una red densa.
EJEMPLO	Documentado (tipo de aplicación): inspección visual automatizada de defectos superficiales en manufactura.
RELACIONES	Convolución (G15), Red densa (G41), Aprendizaje profundo (G13)
FUENTE RASTREABLE	[9], cap. 9 «Convolutional Networks», p. 321; ver [3], entrada «convolutional neural network»

G43 RED NEURONAL RECURRENTE | Recurrent Neural Network (RNN)

DEFINICIÓN TÉCNICA	Familia de redes neuronales para procesar datos secuenciales que comparten parámetros a lo largo del tiempo y mantienen un estado interno que resume la información previa. [9]
EXPLICACIÓN PROPIA	Lee los datos en orden y «recuerda» lo anterior. Sufre con secuencias largas por el desvanecimiento del gradiente; variantes como LSTM lo mitigan.
EJEMPLO	Hipotético: predecir la próxima lectura de temperatura de un horno a partir de las últimas 60.
RELACIONES	Transformer (G44), Desvanecimiento del gradiente (G16), Red densa (G41)
FUENTE RASTREABLE	[9], cap. 10 «Sequence Modeling: Recurrent and Recursive Nets», sec. 10.2, p. 368

G44 TRANSFORMER | Transformer

DEFINICIÓN TÉCNICA	Arquitectura de red basada únicamente en mecanismos de atención, sin recurrencia ni convoluciones, que permite procesar en paralelo todos los elementos de una secuencia. [12]
EXPLICACIÓN PROPIA	Cada token «mira» a todos los demás y decide a cuáles prestar atención. Es la base de los LLM actuales.
EJEMPLO	Documentado: los grandes modelos de lenguaje actuales se basan en variantes del Transformer.
RELACIONES	Red neuronal recurrente (G43), Modelo de lenguaje grande (G50), Modelo fundacional (G51), Tokenización (G30)
FUENTE RASTREABLE	[12], resumen y sec. 3 «Model Architecture»

Eje 12 · Implicaciones sociales

G45 SESGO ALGORÍTMICO | Bias (in AI systems)

DEFINICIÓN TÉCNICA	Sesgo en un sistema de IA que puede producir resultados injustos o discriminatorios; el marco de NIST distingue tres categorías —sistémico, computacional/estadístico y humano-cognitivo— que pueden aparecer incluso sin intención de discriminar. [6]
EXPLICACIÓN PROPIA	Si los datos históricos reflejan desigualdades, el modelo las aprende y las repite a escala. Se detecta comparando métricas por grupo.
EJEMPLO	Documentado (caso público, 2018): se informó que una gran empresa tecnológica abandonó una herramienta experimental de selección de personal que penalizaba currículos asociados a mujeres.
RELACIONES	Explicabilidad (G46), Supervisión humana (G48), Neurona artificial (G37)
FUENTE RASTREABLE	[6], sec. 3.7 «Fair – with Harmful Bias Managed»; ver [3], entrada «bias (ethics/fairness)»
NOTA	Polisemia: ver la nota en «Neurona artificial» sobre el sesgo como parámetro numérico.

G46 EXPLICABILIDAD | Explainability

DEFINICIÓN TÉCNICA	Capacidad de representar los mecanismos que subyacen al funcionamiento de un sistema de IA; se complementa con la interpretabilidad, que se refiere al significado de sus resultados en el contexto para el que fue diseñado. [6]
EXPLICACIÓN PROPIA	No basta con que el modelo acierte: hay que poder explicar por qué, sobre todo en salud, crédito o justicia. Un árbol de decisión es más explicable que una red profunda.
EJEMPLO	Hipotético: un sistema de crédito muestra que el ingreso y el historial de pagos fueron los factores que más pesaron en un rechazo.
RELACIONES	Sesgo algorítmico (G45), Árbol de decisión (G22), Supervisión humana (G48)
FUENTE RASTREABLE	[6], sec. 3.5 «Explainable and Interpretable»; ver [3], entrada «interpretability», y [8], principio «Transparency and explainability»
NOTA	Distinción: según [6], la explicabilidad responde «cómo» se produjo un resultado y la interpretabilidad «qué significa» ese resultado.

G47 PRIVACIDAD DE DATOS | Privacy and data protection

DEFINICIÓN TÉCNICA	Principio según el cual la privacidad debe respetarse, protegerse y promoverse durante todo el ciclo de vida de los sistemas de IA, con marcos adecuados de protección de datos. [8]
EXPLICACIÓN PROPIA	Los modelos se entrenan con datos, a veces personales. Hay que recolectar solo lo necesario, anonimizar y contar con autorización.
EJEMPLO	Hipotético: un hospital entrena un modelo con historias clínicas anonimizadas y con consentimiento informado.
RELACIONES	Sesgo algorítmico (G45), Supervisión humana (G48)
FUENTE RASTREABLE	[8], principio «Right to Privacy, and Data Protection»

G48 SUPERVISIÓN HUMANA | Human oversight

DEFINICIÓN TÉCNICA	Principio según el cual las personas deben poder supervisar los sistemas de IA y conservar la responsabilidad final en las decisiones, especialmente en las irreversibles o de alto impacto. [8]
EXPLICACIÓN PROPIA	La IA puede recomendar, pero en decisiones críticas una persona debe revisar, poder corregir y responder por el resultado.
EJEMPLO	Hipotético: el sistema marca una pieza aeronáutica como defectuosa y un inspector certificado confirma antes de descartarla.
RELACIONES	Explicabilidad (G46), Sesgo algorítmico (G45), Alucinación (G57)
FUENTE RASTREABLE	[8], principio «Human oversight and determination»

Ampliación · Ampliación: IA contemporánea

G49 IA GENERATIVA | Generative AI

DEFINICIÓN TÉCNICA	Campo emergente sin una definición formal; en general, se refiere a modelos capaces de generar contenido complejo, coherente y original, como texto, imágenes, audio o video. [3]
EXPLICACIÓN PROPIA	A diferencia de un clasificador que elige entre opciones, un modelo generativo produce algo que no existía.
EJEMPLO	Documentado: chatbots, generadores de imágenes y asistentes de programación.
RELACIONES	Modelo de lenguaje grande (G50), Modelo de difusión (G59), Alucinación (G57), Modelo fundacional (G51)
FUENTE RASTREABLE	[3], entrada «generative AI»
NOTA	Divergencia: [3] advierte que no existe definición formal y que algunos expertos consideran IA generativa a tecnologías previas (RNN, LSTM) y otros no.

G50 MODELO DE LENGUAJE GRANDE | Large Language Model (LLM)

DEFINICIÓN TÉCNICA	Como mínimo, un modelo de lenguaje con un número muy alto de parámetros; de manera informal, cualquier modelo de lenguaje basado en la arquitectura Transformer. [3]
EXPLICACIÓN PROPIA	Predice el siguiente token una y otra vez. Con suficiente escala, esto le permite responder, resumir, traducir o programar.
EJEMPLO	Documentado: asistentes conversacionales basados en Transformers.
RELACIONES	Transformer (G44), Tokenización (G30), Prompt (G52), Alucinación (G57)
FUENTE RASTREABLE	[3], entrada «large language model»

G51 MODELO FUNDACIONAL | Foundation model

DEFINICIÓN TÉCNICA	Modelo entrenado con datos amplios, generalmente mediante autosupervisión a gran escala, que puede adaptarse (por ejemplo, con ajuste fino) a una amplia gama de tareas posteriores. [15]
EXPLICACIÓN PROPIA	Es una «base» general sobre la que se construyen muchas aplicaciones específicas, en lugar de entrenar un modelo desde cero para cada tarea.
EJEMPLO	Hipotético: una empresa toma un modelo fundacional y lo adapta para responder preguntas sobre sus manuales técnicos.
RELACIONES	Modelo de lenguaje grande (G50), Ajuste fino (G56), IA multimodal (G55)
FUENTE RASTREABLE	[15], sec. 1; ver [3], entrada «foundation model»
NOTA	Nota de fuente: [15] es un reporte del Stanford CRFM, también disponible como preprint en arXiv; se usa por ser el texto que acuñó el término.

G52 PROMPT | Prompt

DEFINICIÓN TÉCNICA	Cualquier texto que se ingresa a un modelo de lenguaje grande para condicionarlo a comportarse de cierta manera; puede ser una pregunta, una instrucción, ejemplos o un rol. [3]
EXPLICACIÓN PROPIA	Es la instrucción o pregunta que se le da al modelo. Un buen prompt aporta contexto, tarea, formato y ejemplos.
EJEMPLO	Hipotético: «Resume este reporte de mantenimiento en 3 viñetas y señala las piezas que deben reemplazarse».
RELACIONES	Modelo de lenguaje grande (G50), Generación aumentada por recuperación (G53), Alucinación (G57)
FUENTE RASTREABLE	[3], entrada «prompt»

G53 GENERACIÓN AUMENTADA POR RECUPERACIÓN | Retrieval-Augmented Generation (RAG)

DEFINICIÓN TÉCNICA	Enfoque que combina un modelo generativo con un mecanismo de recuperación que busca documentos relevantes en una fuente externa y los usa como contexto para generar la respuesta. [13]
EXPLICACIÓN PROPIA	Antes de responder, el sistema «consulta la biblioteca» y responde con base en lo encontrado. Reduce alucinaciones y permite usar información actualizada o privada.
EJEMPLO	Hipotético: un asistente de planta busca en los manuales del fabricante y cita la página exacta del procedimiento.
RELACIONES	Embedding (G32), Base de datos vectorial (G58), Alucinación (G57), Modelo de lenguaje grande (G50)
FUENTE RASTREABLE	[13], resumen y sec. 2; ver [3], entrada «retrieval-augmented generation (RAG)», y [11], cap. 11

G54 AGENTE DE IA | AI agent

DEFINICIÓN TÉCNICA	Software capaz de razonar sobre las entradas del usuario para planificar y ejecutar acciones en su nombre, de forma relativamente autónoma y usando herramientas externas. [3]
EXPLICACIÓN PROPIA	No solo conversa: hace cosas (busca, ejecuta código, llena formularios) y decide el siguiente paso según los resultados.
EJEMPLO	Hipotético: un agente revisa el inventario, detecta un repuesto faltante y redacta la orden de compra para aprobación humana.
RELACIONES	Agente (G17), Modelo de lenguaje grande (G50), Supervisión humana (G48)
FUENTE RASTREABLE	[3], entradas «agent» y «agentic workflow»
NOTA	Divergencia: en RL, «agente» es quien aprende por recompensas; aquí es un sistema que actúa con herramientas.

G55 IA MULTIMODAL | Multimodal model

DEFINICIÓN TÉCNICA	Modelo cuyas entradas, salidas o ambas incluyen más de una modalidad, por ejemplo texto, imágenes, audio y video. [3]
EXPLICACIÓN PROPIA	Puede «ver» una foto y responder en texto, o escuchar audio y generar una imagen.
EJEMPLO	Hipotético: un técnico fotografía una pieza y pregunta «¿qué defecto tiene?»; el modelo responde en texto.
RELACIONES	Modelo fundacional (G51), Red neuronal convolucional (G42), Modelo de lenguaje grande (G50)
FUENTE RASTREABLE	[3], entrada «multimodal model»

G56 AJUSTE FINO | Fine-tuning

DEFINICIÓN TÉCNICA	Segunda etapa de entrenamiento, específica para una tarea, que se aplica a un modelo previamente entrenado para refinar sus parámetros a un caso de uso concreto. [3]
EXPLICACIÓN PROPIA	Se parte de un modelo que ya sabe mucho y se le enseña lo particular con pocos datos, en vez de entrenar desde cero.
EJEMPLO	Hipotético: ajustar un modelo de visión general con 2 000 fotos propias para reconocer defectos de impresión 3D.
RELACIONES	Modelo fundacional (G51), Generación aumentada por recuperación (G53), Conjunto de entrenamiento (G03)
FUENTE RASTREABLE	[3], entrada «fine-tuning»
NOTA	Comparación: RAG añade conocimiento al momento de responder; el ajuste fino cambia los parámetros del modelo.

G57 ALUCINACIÓN | Hallucination

DEFINICIÓN TÉCNICA	Producción, por parte de un modelo de IA generativa, de resultados aparentemente plausibles pero incorrectos en los hechos, cuando el modelo pretende afirmar algo sobre el mundo real. [3]
EXPLICACIÓN PROPIA	El modelo «inventa con seguridad»: una cita bibliográfica falsa, un dato inexistente. Por eso la guía de la actividad prohíbe citar a un chatbot como fuente.
EJEMPLO	Documentado (tipo de caso): se han reportado escritos judiciales con jurisprudencia inexistente generada por chatbots.
RELACIONES	Generación aumentada por recuperación (G53), Supervisión humana (G48), Modelo de lenguaje grande (G50)
FUENTE RASTREABLE	[3], entrada «hallucination»

G58 BASE DE DATOS VECTORIAL | Vector database

DEFINICIÓN TÉCNICA	Sistema que almacena embeddings en un formato óptimo para operaciones como la búsqueda por similitud; en soluciones RAG funciona como índice para recuperar la información más relacionada con una consulta. [5]
EXPLICACIÓN PROPIA	Es el «archivo» donde se guardan significados en forma de números para encontrar lo más parecido en milisegundos. Es una pieza clave de RAG.
EJEMPLO	Hipotético: 50 000 fragmentos de manuales guardados como vectores; la pregunta del técnico se convierte en vector y se buscan los 5 más cercanos.
RELACIONES	Embedding (G32), Generación aumentada por recuperación (G53), K vecinos más cercanos (G33)
FUENTE RASTREABLE	[5], sección «Grounding and RAG»; mecanismo de índice vectorial descrito en [13], sec. 2

G59 MODELO DE DIFUSIÓN | Diffusion model

DEFINICIÓN TÉCNICA	Modelo generativo que aprende a revertir un proceso que añade ruido gradualmente a los datos; para generar, parte de ruido aleatorio y lo elimina paso a paso. [14]
EXPLICACIÓN PROPIA	Aprende a «limpiar» imágenes con ruido; al final puede partir de ruido puro y llegar a una imagen nueva.
EJEMPLO	Documentado: los generadores de imágenes a partir de texto más conocidos usan modelos de difusión.
RELACIONES	IA generativa (G49), IA multimodal (G55)
FUENTE RASTREABLE	[14], resumen y sec. 2

G60 MANTENIMIENTO PREDICTIVO CON IA | AI-based predictive maintenance

DEFINICIÓN TÉCNICA	Estrategia de mantenimiento que analiza datos de los equipos, a menudo provenientes de sensores, mediante técnicas de aprendizaje automático para anticipar fallas e intervenir antes de que afecten la producción. [18]
EXPLICACIÓN PROPIA	En vez de reparar cuando algo se rompe o cambiar piezas por calendario, se interviene cuando el modelo indica riesgo real.
EJEMPLO	Hipotético: un bosque aleatorio analiza vibración y temperatura de motores y alerta 48 h antes de una falla probable.
RELACIONES	Bosque aleatorio (G23), DBSCAN (G11), Regresión (G07)
FUENTE RASTREABLE	[18], resumen

Bibliografía (formato IEEE)

[1] A. Burkov, *The Hundred-Page Machine Learning Book*. Quebec, Canadá: Andriy Burkov, 2019.

[2] O. Theobald, *Machine Learning for Absolute Beginners: A Plain English Introduction*, 2.ª ed. Scatterplot Press, 2017.

[3] Google for Developers, «Machine Learning Glossary». [En línea]. Disponible: https://developers.google.com/machine-learning/glossary. [Consultado: 6 nov. 2026].

[4] scikit-learn developers, «scikit-learn User Guide». [En línea]. Disponible: https://scikit-learn.org/stable/user_guide.html. [Consultado: 6 nov. 2026].

[5] Google Cloud, «Choose models and infrastructure for your generative AI application». [En línea]. Disponible: https://docs.cloud.google.com/docs/ai-ml/generative-ai. [Consultado: 6 nov. 2026].

[6] National Institute of Standards and Technology, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, NIST AI 100-1. Gaithersburg, MD: NIST, 2023. DOI: 10.6028/NIST.AI.100-1.

[7] OECD, «Explanatory memorandum on the updated OECD definition of an AI system», *OECD Artificial Intelligence Papers*, n.º 8, 2024. DOI: 10.1787/623da898-en.

[8] UNESCO, *Recommendation on the Ethics of Artificial Intelligence*. París: UNESCO, 2021.

[9] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. Cambridge, MA: MIT Press, 2016. [En línea]. Disponible: https://www.deeplearningbook.org

[10] R. S. Sutton y A. G. Barto, *Reinforcement Learning: An Introduction*, 2.ª ed. Cambridge, MA: MIT Press, 2018.

[11] D. Jurafsky y J. H. Martin, *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models*, 3.ª ed. Manuscrito en línea, versión del 6 ene. 2026. [En línea]. Disponible: https://web.stanford.edu/~jurafsky/slp3/. [Consultado: 6 nov. 2026].

[12] A. Vaswani *et al.*, «Attention is all you need», en *Advances in Neural Information Processing Systems 30 (NeurIPS)*, 2017.

[13] P. Lewis *et al.*, «Retrieval-augmented generation for knowledge-intensive NLP tasks», en *Advances in Neural Information Processing Systems 33 (NeurIPS)*, 2020.

[14] J. Ho, A. Jain y P. Abbeel, «Denoising diffusion probabilistic models», en *Advances in Neural Information Processing Systems 33 (NeurIPS)*, 2020.

[15] R. Bommasani *et al.*, «On the opportunities and risks of foundation models», Stanford Center for Research on Foundation Models (CRFM), 2021. [En línea]. Disponible: https://crfm.stanford.edu/assets/report.pdf. También arXiv:2108.07258.

[16] M. Ester, H.-P. Kriegel, J. Sander y X. Xu, «A density-based algorithm for discovering clusters in large spatial databases with noise», en *Proc. 2nd Int. Conf. Knowledge Discovery and Data Mining (KDD-96)*, 1996, pp. 226–231.

[17] L. Breiman, «Random forests», *Machine Learning*, vol. 45, n.º 1, pp. 5–32, 2001. DOI: 10.1023/A:1010933404324.

[18] T. P. Carvalho, F. A. A. M. N. Soares, R. Vita, R. da P. Francisco, J. P. Basto y S. G. S. Alcalá, «A systematic literature review of machine learning methods applied to predictive maintenance», *Computers & Industrial Engineering*, vol. 137, art. 106024, 2019. DOI: 10.1016/j.cie.2019.106024.

Anexo A. Matriz de trazabilidad de fuentes

Estados al 6 nov. 2026. **Contenido cotejado**: se abrió la fuente y se comparó la definición con la paráfrasis. **Localizador confirmado**: se confirmó que el capítulo, sección o página existe y trata el tema. **Cotejado en 2.ª revisión**: fuente revisada en una segunda pasada asistida por IA (ver Anexo B). La columna **Eq.** (equipo) se marca cuando un integrante abre la fuente y confirma la cita por su cuenta.

ID	Fuente	Tipo	Localizadores usados	Términos (ID)	Estado	Eq.
[1]	Burkov (2019), The Hundred-Page ML Book	Libro base	sec. 2.7 «Classification vs. Regression» y sec. 3.1; cap. 3, sec. 3.2 «Logistic Regression»; cap. 3, sec. 3.3 «Decision Tree Learning», p. 27; cap. 2 «Notation and Definitions»; cap. 2, sec. 2.4 «Bayes' Rule», p. 17; cap. 3, sec. 3.5 «k-Nearest Neighbors», p. 34	G07, G21, G22, G27, G28, G33, G36	Localizadores confirmados (índice y páginas)	☐
[2]	Theobald (2017), ML for Absolute Beginners	Libro base	cap. «What is Machine Learning?»; capítulo «Clustering»; capítulo «Bias & cap. «Artificial Neural Networks»	G02, G09, G24, G37	Localizadores confirmados (capítulos)	☐
[3]	Google for Developers, ML Glossary (s. f.)	Técnica	entrada «artificial intelligence»; entrada «machine learning»; entrada «training set»; entrada «inference»; entrada «label»; entrada «classification model» …	G01, G02, G03, G04, G05, G06, G07, G08, G09, G13, G15, G16, G17, G21, G22, G23, G24, G25, G26, G30, G32, G34, G35, G36, G37, G38, G39, G40, G41, G42, G45, G46, G49, G50, G51, G52, G53, G54, G55, G56, G57	Contenido cotejado	☐
[4]	scikit-learn, User Guide (s. f.)	Técnica	sección «Clustering», apartado «K-means»; sección «Clustering», apartado «DBSCAN»; sección «Decomposing signals in components», apartado «PCA»; sección «Nearest Neighbors»; sección «Nearest Neighbors» (parámetro n_neighbors); sección «Preprocessing data», apartado «Standardization», y [1], cap. 5 «Basic Practice»	G10, G11, G12, G33, G34, G36	Cotejado en 2.ª revisión	☐
[5]	Google Cloud, Choose models and infrastructure for gen AI (s. f.)	Técnica	sección «Grounding and RAG»	G58	Contenido cotejado	☐

ID	Fuente	Tipo	Localizadores usados	Términos (ID)	Estado	Eq.
[6]	NIST, AI RMF 1.0, AI 100-1 (2023)	Institucional	sec. 3.7 «Fair – with Harmful Bias Managed»; sec. 3.5 «Explainable and Interpretable»	G45, G46	Cotejado en 2.ª revisión	☐
[7]	OCDE, definición de sistema de IA (2024)	Institucional	definición actualizada de «AI system»	G01	Cotejado en 2.ª revisión	☐
[8]	UNESCO, Ética de la IA (2021)	Institucional	principio «Right to Privacy, and Data Protection»; principio «Human oversight and determination»	G46, G47, G48	Cotejado en 2.ª revisión	☐
[9]	Goodfellow et al., Deep Learning (2016)	Académica	cap. 1 «Introduction», p. 1; cap. 1 y cap. 15 «Representation Learning»; cap. 9, sec. 9.1 «The Convolution Operation», p. 322; cap. 10, sec. 10.7, p. 390; cap. 4, sec. 4.3 «Gradient-Based Optimization», p. 79; cap. 6, sec. 6.5 «Back-Propagation and Other Differentiation Algorithms», p. 197 …	G13, G14, G15, G16, G39, G40, G42, G43	Localizadores confirmados (secciones y páginas)	☐
[10]	Sutton y Barto, RL (2018)	Académica	cap. 1, sec. 1.3 y cap. 3; cap. 1, sec. 1.3; cap. 6, sec. 6.5 «Q-learning: Off-policy TD Control», p. 131	G17, G18, G19, G20	Localizador confirmado (sec. 6.5, p. 131)	☐
[11]	Jurafsky y Martin, SLP 3.ª ed. (ene. 2026)	Académica	cap. 1 «Introduction»; cap. 2 «Words and Tokens»; cap. 11 «Information Retrieval and Retrieval-Augmented Generation», apartado tf-idf; cap. 5 «Embeddings»	G29, G30, G31, G32, G53	Capítulos confirmados en el índice en línea	☐
[12]	Vaswani et al. (2017)	Académica	resumen y sec. 3 «Model Architecture»	G44	Cotejado en 2.ª revisión	☐
[13]	Lewis et al. (2020)	Académica	resumen y sec. 2	G53, G58	Cotejado en 2.ª revisión	☐
[14]	Ho et al. (2020)	Académica	resumen y sec. 2	G59	Cotejado en 2.ª revisión	☐
[15]	Bommasani et al. (2021), Stanford CRFM	Académica (reporte)	sec. 1	G51	Cotejado en 2.ª revisión	☐
[16]	Ester et al. (1996)	Académica	Obra completa / secciones indicadas	G11	Cotejado en 2.ª revisión	☐
[17]	Breiman (2001)	Académica	Obra completa / secciones indicadas	G23	Cotejado en 2.ª revisión	☐
[18]	Carvalho et al. (2019)	Académica	resumen	G60	Resumen y autores cotejados	☐

Anexo B. Nota metodológica y verificación

Selección de términos

Se eligieron 4 términos por cada uno de los 12 ejes de la guía (48) y 12 términos de ampliación sobre IA contemporánea, con prioridad a conceptos que se conectan entre sí y con aplicaciones de manufactura, control de calidad y mantenimiento predictivo.

Criterios de fuentes

Se usaron 18 fuentes independientes: los dos libros base de la guía (Burkov y Theobald), documentación técnica oficial (Google for Developers, scikit-learn, Google Cloud), fuentes institucionales (NIST, OCDE, UNESCO) y fuentes académicas originales (libros de referencia y artículos que introdujeron cada técnica). Para fundamentos se aceptaron obras clásicas indicando su fecha; para términos contemporáneos se priorizó documentación vigente o el texto original.

Cómo se verificaron las definiciones

Cada definición técnica es una paráfrasis de la fuente indicada en la propia ficha. La verificación se hizo en dos pasadas. En la primera se comparó el texto de más de 30 entradas del *Machine Learning Glossary* de Google [3] y la página de Google Cloud [5], y se confirmaron capítulos, secciones y páginas de [1], [2], [9] y [10]. En la segunda se revisaron las fuentes restantes y se hizo un control cruzado de la primera. El estado de cada fuente se registra en el Anexo A.

Correcciones realizadas

A partir de la verificación se ajustaron las definiciones de IA generativa, LLM, prompt, agente de IA, alucinación, base de datos vectorial, neurona artificial, sesgo algorítmico, explicabilidad y mantenimiento predictivo. La referencia [6] se cambió del documento NIST AI 100-3 (que describe un glosario publicado como hoja de cálculo aparte) al NIST AI RMF 1.0, cuyas secciones 3.5 y 3.7 tratan explicabilidad y sesgo. En [11] se actualizaron los capítulos a la versión en línea de enero de 2026, en la que tf-idf pasó al capítulo 11. En [18] se confirmó el orden de autores (primer autor: T. P. Carvalho). La distancia euclidiana se cita desde la entrada «k-median» de [3], porque el glosario no tiene una entrada independiente.

Divergencias entre fuentes

Cuando las fuentes difieren (por ejemplo, «inteligencia artificial», «inferencia», «agente», «sesgo», «IA generativa» o la ubicación de tf-idf entre ediciones), la ficha incluye una nota que explica la diferencia y la interpretación adoptada.

Ejemplos

Los ejemplos se marcan como *documentado* (caso o tipo de aplicación reportado públicamente), *hipotético* (escenario construido para ilustrar el concepto) o *calculado* (operación verificable).

Declaración de uso de inteligencia artificial

Se utilizaron dos asistentes de IA: Claude (Anthropic), para organizar la estructura, proponer borradores de explicaciones y ejemplos, diseñar y programar el juego, y buscar y comparar fuentes en la primera verificación; y ChatGPT (OpenAI), para una segunda revisión del glosario y del reglamento. Ningún asistente se cita como fuente de una definición: todas remiten a fuentes

publicadas. Las propuestas de los asistentes se contrastaron entre sí y con las fuentes; por ejemplo, la segunda revisión cambió por error el primer autor de [18] y ubicó tf-idf en un capítulo incorrecto, y ambos errores se corrigieron al cotejar la fuente original. El equipo es responsable del contenido final y registra su propia comprobación en la columna «Eq.» del Anexo A.